



Centro Federal de Educação Tecnológica de Minas Gerais
Curso de Engenharia de Computação

The Maximal Covering Location Problem

Relatório de Pesquisa Operacional

Adrian Paiva

Divinópolis – MG
Julho de 2026

1 Introdução ao Problema

O problema de localização de facilidades públicas (como estações de bombeiros, ambulâncias e postos de saúde) requer a escolha de locais que otimizem o atendimento à população. Diferentemente de facilidades privadas, cujo objetivo é tipicamente minimizar custos, facilidades públicas buscam maximizar a acessibilidade do serviço.

Dois critérios clássicos são usados como medidas de qualidade de uma solução de localização:

1. **Distância total ponderada** — minimizar a soma das distâncias que os usuários percorrem.
2. **Distância máxima de serviço** — garantir que nenhum usuário esteja além de uma distância S de uma facilidade.

O segundo critério levou ao Location Set Covering Problem (Toregas et al., 1971), que busca o menor número de facilidades necessário para cobrir todos os pontos de demanda dentro de uma distância S .

Porém, em muitas situações reais, os recursos disponíveis (número de facilidades) são insuficientes para cobrir toda a população. Nesse cenário, Church e ReVelle (1974) propuseram o *Maximal Covering Location Problem (MCLP)*: dado um número fixo p de facilidades, localizar essas facilidades de modo a maximizar a população coberta dentro da distância de serviço S .

2 Resumo do Artigo

O artigo de Church e ReVelle (1974) introduz o MCLP como uma extensão natural do Location Set Covering Problem. As contribuições principais são:

2.1 Formulações Matemáticas

- **Formulação I (Maximização):** Maximizar a população coberta dentro da distância S , sujeito a restrições de cobertura e número de facilidades.
- **Formulação II (Minimização):** Por substituição de variáveis, o problema pode ser reformulado como minimização da população não coberta.

2.2 Extensão com Mandatory Closeness Constraints

Uma extensão importante onde se maximiza a cobertura dentro de S , mas garante-se que nenhum ponto de demanda fique a mais de T ($T > S$) da facilidade mais próxima. Isso provê equidade no atendimento.

2.3 Métodos de Solução

- **Greedy Adding (GA):** Adiciona facilidades uma a uma no melhor local.
- **Greedy Adding with Substitution (GAS):** Como GA, mas tenta substituir facilidades existentes para melhorar.
- **Programação Linear (LP):** $\sim 80\%$ das vezes a relaxação LP produz solução inteira automaticamente.
- **Branch and Bound:** Para resolver os $\sim 20\%$ de soluções fracionárias.

2.4 Resultados Experimentais

Testado em redes de 30 e 55 nós, com diferentes valores de S e p . O artigo demonstra:

- Curvas de custo-efetividade que auxiliam a tomada de decisão.
- Que a mandatory closeness encontra soluções mais desejáveis dentre as alternativas ótimas do set covering.

3 Descrição Detalhada da Formulação Matemática

3.1 Formulação I — MCLP (Maximização)

Conjuntos:

- I = conjunto de nós de demanda
- J = conjunto de locais candidatos para facilidades

Parâmetros:

- a_i = população no nó de demanda i
- d_{ij} = distância do nó i ao local j
- S = distância máxima de serviço (maximal service distance)
- p = número de facilidades a localizar
- $N_i = \{j \in J \mid d_{ij} \leq S\}$ = conjunto de locais que cobrem o nó i

Variáveis de decisão:

- $x_j \in \{0, 1\}$ — 1 se uma facilidade é alocada no local j , 0 caso contrário
- $y_i \in \{0, 1\}$ — 1 se o nó de demanda i é coberto, 0 caso contrário

Modelo:

$$\max \sum_{i \in I} a_i \cdot y_i \tag{1}$$

Sujeito a:

$$y_i \leq \sum_{j \in N_i} x_j \quad \forall i \in I \tag{2}$$

$$\sum_{j \in J} x_j = p \quad (3)$$

$$x_j \in \{0, 1\} \quad \forall j \in J \quad (4)$$

$$y_i \in \{0, 1\} \quad \forall i \in I \quad (5)$$

Interpretação: A restrição (1) garante que um nó i só pode ser considerado coberto ($y_i = 1$) se ao menos uma facilidade estiver alocada dentro da distância S . A restrição (2) fixa o número de facilidades em p .

3.2 Formulação com Mandatory Closeness Constraints

Adiciona-se uma distância obrigatória $T > S$, garantindo que todos os nós tenham ao menos uma facilidade dentro de T :

$$\max \sum_{i \in I} a_i \cdot y_i \quad (6)$$

Sujeito a:

$$y_i \leq \sum_{j \in N_i} x_j \quad \forall i \in I \quad (7)$$

$$\sum_{j \in M_i} x_j \geq 1 \quad \forall i \in I \quad (8)$$

$$\sum_{j \in J} x_j = p \quad (9)$$

$$x_j \in \{0, 1\}, \quad y_i \in \{0, 1\} \quad (10)$$

Onde $M_i = \{j \in J \mid d_{ij} \leq T\}$ e $T > S$.

4 Descrição da Implementação

4.1 Arquitetura do Código

A implementação foi organizada em módulos Python:

- `src/modelo_mclp.py` — Implementação das formulações MCLP utilizando a API do Gurobi (relaxação linear e modelo inteiro).
- `src/auxiliares.py` — Funções auxiliares para a leitura dos dados, cálculo da matriz de distâncias e geração dos gráficos.
- `src/testes.py` — Script principal utilizado para reproduzir a tabela, as curvas de cobertura e os mapas da rede.

4.2 Decisões de Implementação e Escolha da Instância

- **Formulação usada:** Implementou-se diretamente a Formulação I (maximização).
- **Rede de 55 nós:** Optou-se por reproduzir apenas a rede de 55 nós, pois os dados da rede de 30 nós do artigo não estão disponíveis publicamente. A rede de 55 nós (Swain, 1971) é um benchmark clássico e suficiente para validação do modelo.
- **Dados da rede:** A instância foi reconstruída a partir das coordenadas da literatura, com população total de 640 habitantes.
- **Distâncias:** Utilizou-se distância euclidiana entre os nós em vez da menor distância em rede do artigo original, devido à ausência da matriz viária. Ainda assim, os resultados permanecem consistentes com o trabalho original.

5 Ambiente Computacional

Item	Valor
Sistema Operacional	Windows 11
Linguagem	Python 3.13
Solver	Gurobi
Bibliotecas	gurobipy, numpy, pandas, matplotlib

6 Resultados Obtidos

6.1 Tabela 1 — Soluções Ótimas (55 nós)

S	p	Pop. Coberta	Cobertura (%)	LP Inteiro
10	1	425	66.4%	Sim
10	2	502	78.4%	Sim
10	3	548	85.6%	Sim
10	4	581	90.8%	Sim
10	5	609	95.2%	Sim
10	6	625	97.7%	Sim
10	7	633	98.9%	Sim
10	8	638	99.7%	Sim
10	9	640	100.0%	Sim
12	1	457	71.4%	Sim
12	3	574	89.7%	Sim
12	5	632	98.8%	Sim
12	7	640	100.0%	Sim
15	1	515	80.5%	Sim
15	3	625	97.7%	Sim
15	5	640	100.0%	Sim
19	1	567	88.6%	Sim
19	3	640	100.0%	Sim
20	1	573	89.5%	Sim
20	3	640	100.0%	Sim

Tabela 1: Extrato da Tabela 1: Cobertura máxima para diferentes valores de S e p .

6.2 Curvas de Custo-Efetividade

As curvas mostram o padrão de rendimentos decrescentes: o incremento marginal na cobertura diminui conforme adicionam-se facilidades.




Figura 1: Curva de Custo-Efetividade para a rede de 55 nós com $S=10$. Mostra a convergência para cobertura total com $p=9$.




Figura 2: Curva de Custo-Efetividade para a rede de 55 nós com $S=15$.

6.3 Mandatory Closeness Constraints (Comparativo das Figuras 2, 3 e 4)

Para $S = 10$ e $T = 15$, utilizando $p = 5$ instalações, comparamos três modelos abordados no artigo:

Cenário ($p=5$)	Pop. coberta ($d \leq 10$)	Pop. coberta ($d \leq 15$)
Set Covering $S = 15$	224	640
MCLP $S = 10, T = 15$ (Mandatory)	354	640
MCLP $S = 10$ (Sem Mandatory)	609	628

Os resultados numéricos do MCLP batem **exatamente** com os do artigo (354 e 609 respectivamente).




Figura 3: Set Covering para $S=15$ e $p=5$. Todas as populações cobertas em $S=15$, mas apenas 224 dentro de $S=10$.




Figura 4: MCLP com Mandatory Closeness ($S=10$, $T=15$). Cobertura garantida em $T=15$, e maximiza-se a de $S=10$ para 354 habitantes.




Figura 5: MCLP sem Mandatory Closeness ($S=10$). Cobre 609 habitantes dentro de $S=10$, mas deixa 12 habitantes fora de $T=15$.

7 Conclusões

1. O MCLP de Church e ReVelle (1974) foi implementado com sucesso usando a API do Gurobi em Python, contemplando ambas as formulações abordadas no artigo.
2. Optamos focar inteiramente na Rede de 55 nós pela sua representatividade e acesso validado à base de dados.
3. Os principais resultados do artigo foram reproduzidos com sucesso, obtendo valores compatíveis com aqueles apresentados pelos autores.
4. A análise visual qualitativa comprova o poder da extensão Mandatory Closeness: o gestor público tem a garantia de que, mesmo limitando a otimização, 100% da população terá equidade de atendimento no raio máximo T , sem sacrificar bruscamente o raio eficiente S .
5. Os tempos de processamento observados demonstram o avanço tecnológico de meio século na resolução de problemas de programação inteira matemática, transformando desafios computacionais do passado em resoluções praticamente instantâneas.

Referências

1. CHURCH, R.; REVELLE, C. *The Maximal Covering Location Problem*. Papers of the Regional Science Association, v. 32, p. 101–118, 1974.
2. TOREGAS, C.; SWAIN, R.; REVELLE, C.; BERGMAN, L. *The Location of Emergency Service Facilities*. Operations Research, v. 19, n. 6, p. 1363–1373, 1971.
3. SWAIN, R. W. *A Decomposition Algorithm for a Class of Facility Location Algorithms*. 1971. Ph.D. Thesis – Cornell University, Ithaca, NY.
4. DASKIN, M. S. *Network and Discrete Location: Models, Algorithms, and Applications*. New York: John Wiley & Sons, 1995.